



01_[이론] 검정 이론

강의자료

- 빅데이터분석기사실기.pdf_
- ADsP 강의_슬라이드_2025.pdf 126-133page

통계 분석 why?

- 주장하고 싶은 내용의 근거를 잘 뒷받침하기 위해 사용
- 가설을 어떻게 설정하느냐에 따라 달려있음

A 가설 설정 → 증명 (시각화, 기초통계(=모수검정))

- 내가 주장하는 바와 배치되는 지, 실제 증명이 되는 지 확인
- 각각에 대해서 인사이트 도출

통계 3가지

- 모수 검정
- 비모수 검정
- 베이지안 통계 (베이즈 확률 이론 기반)
 - 사후분포
 - ex) 이성친구 바람피는 것 : 의심

모수검정과 비모수 검정의 가장 큰 차이점 → 데이터의 갯수

- 데이터가 많다 (행 개수 30개 초과) → 모수 검정
- 데이터가 적다 (행 개수 30개 이하) → 비모수 검정

모수검정

- 평균

데이터 분석은 가설이 중요함

가설이란?? → "평균 차이 검정" → 2개 그룹이 필요

⇒ 가설 = 2개 그룹의 평균 차이 검정

→ 고려할 사항 : 수치화, 계량화를 어떻게 하지???

이러한 데이터들을 수집해야 함

01. 가설 검정 주요 용어

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ 가설 (Hypothesis)

✓ 모집단의 특성, 특히 모수에 대한 가정 혹은 잠정적인 결론이다.

종류	설명
귀무가설 (H_0 , Null Hypothesis)	- 기존과 비교하여 변화 혹은 차이가 없음을 나타내는 가설 - 검정 방법에 따라 귀무가설의 내용이 달라짐
대립가설 (H_1 , Alternative Hypothesis)	- 표본을 통해 확실한 근거를 가지고 입증하고자 하는 가설 - 연구가설 (Research Hypothesis) 이라고도 함

◆ 가설 검정 시, 관심 있는 가설은 대립가설이며, 대립가설이 참이라는 확실한 근거가 없다면 귀무가설 채택

✓ 표현문구는 귀무가설 채택 (X), **귀무가설을 기각하지 못한다** (O)

✓ 대립가설이 참이라는 확실한 근거 발견 시, **귀무가설을 기각한다**(O) 표현

가설

- 귀무가설 - 평균 차이가 없음 (변화가 없다)
- 대립가설 - 평균 차이가 있음 (변화가 있다)

중심극한정리

01. 가설 검정 주요 용어

(2023년 11월 기준)


◆ 중심 극한 정리(CLT : Central Limit Theorem)

✓ 정의 : 정규분포가 아닌 분포라도 선택된 표본들의 평균을 모아 다시 분포를 그리면 정규분포가 됨

✓ 단, 최소 표본의 크기가 작으면 안됨 ($n \geq 30$)

✓ CLT에 따르면, Sampling Distribution은 정규분포를 따름

✓ 모든 모집단 데이터의 평균 = 모든 샘플 평균들의 평균 = Sampling Distribution의 평균



출처 : <https://corporatefinanceinstitute.com/resources/data-science/central-limit-theorem/>

핵심은 "정규분포"

모수 검정의 모든 이론은 "정규분포"에서 출발한다

중심극한정리의 의미

- t검정, 분산분석, 회귀분석
- 전제조건 : 수집된 데이터는 정규분포를 이루어야 한다.
- 만약 수집된 데이터가 정규분포가 아니면, 수단과 방법을 가리지 말고 정규분포로 만들
→ 데이터를 변환 (로그 변환, oo변환 등)을 활용

→ 그래도 정규분포가 아니면 → 비모수 검정 방법론을 활용

Q. 통계는 무조건 데이터가 많으면 다 좋은건가?

A. 물량이 중요한 것이 아닌, 얼마나 과학적으로 샘플링을 했냐가 중요!

ex) 20대 남녀 평균 임금 차이

- 남자들 → 군대에서 샘플링, 30만명

- 여자들 → 1000명

→ 샘플링은 무조건 "층화추출"하자!

——> 층화추출 : 그룹 당 비율에 따라서 비율에 맞춰서 샘플링을 하는 것

——→ ex) A 그룹 100명, B 그룹 50명 → A그룹 : 10명, B그룹 : 5명

SQL에서는 층화추출 함수가 없으니, 별도로 메서드를 만들어야 함

분석 시 경계해야 할 건 → 왜곡 & 편향성

→ 이를 방지하기 위해 층화추출함

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ 가설 검정 오류

✓ 다음과 같은 통계적 오류가 발생할 가능성이 항상 존재함

	귀무가설(H_0)이 사실이라고 판정 (무죄)	귀무가설(H_0)이 거짓이라고 판정 (유죄)
귀무가설(H_0)이 사실	옳은 결정 No Error ($1-\alpha$) 무죄를 무죄라 함	제1종 오류 무죄를 유죄라 함
귀무가설(H_0)이 거짓	제2종 오류 유죄를 무죄라 함	옳은 결정 No Error ($1-\beta$) 유죄를 유죄라 함

분석에 있어서 가장 확실한 방법 : 전수조사

→ 그러나 시간이 오래 걸림 (현실적으로 불가능)

→ "표본조사" 시행 - 근사하지만, 오차 발생할 수 밖에 없음 (잘못된 가능성이 존재할 수 있음)

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ 의사결정의 원칙

- ✓ 귀무가설이 옳다는 가정하에 H_1 이 옳다는 증거를 제시해야 함 (Presumed Innocence)

◆ 의사결정의 기준

- ✓ 가장 주의해야 하는 것은 1종 오류를 범하는 것
 - 나의 주장이 옳지 않은데 옳다고 결론 내리는 것
- ✓ 의사결정의 기준은 1종 오류를 범할 확률(유의 수준 α)

	의사결정	설명
$\alpha = 0$	H_0	무죄인 사람을 유죄라고 판단 할 오류 0%
$\alpha = 0.01$ (1%)	H_0 : 99% H_1 : 1%	매우 보수적이며 엄격한 판단 표본에서 구한 통계량 값이 나올 확률이 1%보다 작을 때 의미
$\alpha = 0.05$ (5%)	H_0 : 95% H_1 : 5%	오류가 5%까지 허용 상대적으로 덜 엄격한 의사결정

산업군마다 다름

- 의료 : 0.01
- 사회과학 논문 : 0.05
- 마케팅 : 0.1

통계는 항상 오류가 날 가능성이 존재한다
→ WHY? 전수조사가 아니기 때문

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ p-value와 임계값

- ✓ 귀무가설 H_0 가 참일 때 표본에서 얻어진 결과가 귀무가설을 기각하게 하는 확률
- ✓ 주어진 유의수준 α 하에서 귀무가설 H_0 의 채택 또는 기각 여부를 판정하여 주는 기준이 되는 값

Critical regions for a two-sided test

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ p-value와 임계값

- ✓ 귀무가설 H_0 가 참일 때 표본에서 얻어진 결과가 귀무가설을 기각하게 하는 확률
- ✓ 주어진 유의수준 α 하에서 귀무가설 H_0 의 채택 또는 기각 여부를 판정하여 주는 기준이 되는 값

p-value	Sig. stars	해석	귀무가설
$p > 0.05$		통계적으로 유의하지 않음	채택(Retained)
$p < 0.05$	*	통계적으로 유의함($\alpha = 0.05$)	기각(Rejected)
$p < 0.01$	**	통계적으로 유의함($\alpha = 0.01$)	기각(Rejected)
$p < 0.001$	***	통계적으로 유의함($\alpha = 0.001$)	기각(Rejected)

p-value 보고 귀무가설/대립가설 채택 여부 결정

- 귀무가설 채택 = 대립가설 기각 = 평균차이가 없다
- 귀무가설 기각 = 대립가설 채택 = 평균차이가 있다

02. 가설 검정 기법 - 단일 표본 T-검정

02. 가설 검정 기법 - 단일표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 모평균 μ 에 대한 검정 절차로 다음과 같이 귀무가설과 대립가설 설정

가설	표현식	설명
H_0	$\mu = \mu_0$	모평균과 표본평균은 같다
H_1	$\mu \neq \mu_0$	모평균과 표본평균은 같지 않다.

◆ 검정통계량

- ✓ 모분산을 알고 있을 때,

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$$

$\bar{X}$: 표본평균

σ : 모분산

n : 표본의 갯수

모평균 : A (기본적으로 알려진 사실)

표본 평균 : B

→ A 평균과 B 평균은 같다 / 다르다 비교

02. 가설 검정 기법 - 단일표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 실습

- ✓ 모평균의 값을 알고 있을 때

```
1 : from scipy import stats
2 : t_score, p_value = stats.ttest_1samp(df['Height'], popmean=75)
3 : print(round(t_score, 2), round(p_value, 2))
0.87, 0.39
```

◆ 메서드 설명

- ✓ 독립 관측치 샘플 array의 예상값(평균)이 주어진 모집단 평균인 popmean과 같다는 귀무 가설에 대한 검정.

메서드	매개변수	설명
<code>ttest_1samp(array, popmean)</code>	array	Sample Observation
	popmean	Expected value in null hypothesis

p_value 값 : 0.39

→ 0.39 > 0.05보다 큼 → 귀무가설 채택 → 평균 차이 없음

03. 가설 검정 기법 - 독립 표본 T-검정

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 두개의 독립 표본 X, Y가 각각 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 를 따를 때, 두 모집단의 평균 차이 $\mu_1 - \mu_2$ 의 검정은 다음과 같음.

가설	표현식	설명
H_0	$\mu_1 = \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같다.
H_1	$\mu_1 \neq \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같지 않다.

◆ 가정(Assumptions) 확인

- ✓ 독립성
- ✓ Normality 정규성
- ✓ Homogeneity of Variance 분산의 동질성

독립 표본 T-검정 → 서로 성격이 다른 그룹들 검정

• 가정 확인

- Normality 정규성 (각 그룹에 모두 적용, 선택)
 - 그룹 1과 그룹 2 각각 정규성 검정
- 분산의 동질성 (꼭 해야 함)
 - 귀무가설 : 두 그룹의 분포는 같을까요? 다를까요? → 같다!

- 대립가설 : 두 그룹의 분포는 다르다!

→ 분포가 다르면 비모수 검정을 실시 (분포가 같도록 만들기!)

이 위의 조건을 만족해야만 독립표본 T-검정 할 수 있음

정규성 or 분산의 동질성을 만족하지 못할 경우 비모수 검정 실시

제미나이 GEMS (데이터 분석 명저 마스터) 참고

<https://gemini.google.com/gem/eda0e597292f>

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 정규성 검정

- ✓ 각 그룹의 표본수가 $N \leq 30$ 이하일 때, 검정해야 함
- ✓ 각 그룹의 표본수가 모두 $N \geq 30$ 이상일 때, 중심극한정리에 의해 정규성 가정을 만족했다고 봄

가설	설명
H_0	각 자료는 정규분포를 따른다.
H_1	각 자료는 정규분포를 따르지 않는다.

◆ 확인 방법

- ✓ Shapiro-Wilk tests

◆ 가정 위반 시, Mann-Whitney Test를 진행

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 등분산성 검정

- ✓ 각 그룹의 데이터수가 다르면 분산이 같은지 검정
- ✓ 만약에 각 그룹의 데이터수가 동일하면, 분산이 같다고 가정함

가설	설명
H_0	두 그룹의 분산은 차이가 없음
H_1	두 그룹의 분산은 차이가 있음

◆ 확인 방법

- ✓ bartlett, fligner, levene 검정 주로 사용
- ✓ 일반적으로는 levene 검정을 주로 사용

◆ 가정 위반 시

- ✓ Welch Test 사용

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 두개의 독립 표본 X, Y 가 각각 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 를 따를 때, 두 모집단의 평균 차이 $\mu_1 - \mu_2$ 의 검정은 다음과 같다.

가설	표현식	설명
H_0	$\mu_1 = \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같다.
H_1	$\mu_1 \neq \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같지 않다.

◆ 검정통계량

- ✓ 그룹 1의 표본평균 $\bar{X}$, 그룹 2의 표본평균 $\bar{Y}$ 의 차이에 근거하여 구성
- ✓ 검정통계량 T 는 자유도 $n + m - 2$ 인 t -분포를 따른다.

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}}, S_p^2 = \frac{(n-1)s_1^2 + (m-1)s_2^2}{n+m-2}$$

S_p^2 : 공통분산 σ^2 의 합동 표본분산
 $n-1$: 그룹 1 표본의 자유도
 $m-1$: 그룹 2 표본의 자유도

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 등분산성 검정 실습

- ✓ 데이터의 각 변수들은 정규분포를 만족하며, 두 그룹은 등분산을 만족한가?

```

1 : from scipy import stats
2 : stats.levene(df.loc[df['supp'] == "VC", 'len'], df.loc[df['supp'] == "OJ", 'len'])
LeveneResult(statistic=1.2135720656945064, pvalue=0.2751764616144053)
  
```

◆ 메서드 설명

- ✓ Levene 검정은 모든 입력 샘플이 동일한 분산을 가진 모집단에서 나온 것이라는 귀무가설을 테스트 함

메서드	매개변수	설명
<code>levene(sample1, sample2, ...)</code>	sample1 : array_like	The sample data, possibly with different lengths. Only one-dimensional samples are accepted.

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 독립표본 t-검정

- ✓ 데이터의 각 변수들은 정규분포를 만족하며, 두 그룹은 등분산을 만족한다!

```
1 : from scipy import stats
2 : t_score, p_value = stats.ttest_ind(df.loc[df['supp'] == "VC", 'len'],
                                     df.loc[df['supp'] == "OJ", 'len'], equal_var = True)
3 : print(round(t_score, 4), round(p_value, 2))
-1.9153 0.06
```

◆ 메서드 설명

- ✓ 이 검정은 두 독립 샘플의 평균(예상) 값이 동일하다는 귀무가설에 대한 검정.
- ✓ 두 집단의 분산이 동일하다고 가정함.

메서드	매개변수	설명
ttest_ind(a, b, equal_var)	a, b	데이터의 크기가 동일해야 함.
	equal_var	If true, independent t-test / If false, Welch's t-test

p_value = 0.06 → 귀무가설 채택 → 두 그룹의 평균은 같다

04. 가설 검정 오류 - 대응표본 T-검정

04. 가설 검정 기법 - 대응표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 실험단위를 동일한 쌍으로 묶은 다음, 각 쌍에서 관측값의 차를 이용하여 두 모평균의 차이에 관한 추론
- ✓ 실험 이전의 집단과 실험 이후의 집단이 동일한 경우 사용하는 검정(쌍체비교)이라고 한다.
- ✓ $(X_1, Y_1), (X_2, Y_2), (X_3, Y_3), \dots, (X_n, Y_n)$
- ✓ 각 쌍의 차이를 $D_i = X_i - Y_i (i = 1, 2, \dots, n)$ 로 정의할 때, D_i 는 $N(\mu_D, \sigma_D^2)$ 으로부터의 확률표본으로 가정한다.
- ✓ $\mu_D = \mu_1 - \mu_2$

가설	표현식	설명
H_0	$\mu_D = 0$	실험전후 평균의 차이는 0이다
H_1	$\mu_D \neq 0$	실험전후 평균의 차이는 0이 아니다

◆ 가정(Assumptions) 확인

- ✓ 독립성
- ✓ 정규성

- 어떤 트리거가 있는데, 실험 전/후 평균을 비교할 때
ex) 임상실험, 교육효과
- 두 차이가 클 경우는 할 필요가 없음

04. 가설 검정 기법 - 대응표본 T-검정

(2023년 11월 기준)

◆ 정규성 검정

- ✓ 실험전후 두 변수의 차이가 정규분포를 따르는지 확인. $N \leq 30$ 이하일 때, 검정해야 함
- ✓ 각 그룹의 변수가 정규분포를 따르는지는 검정할 필요가 없음
- ✓ 각 그룹의 표본수가 모두 $N \geq 30$ 이상일 때, 중심극한정리에 의해 정규성 가정을 만족했다고 봄

가설	설명
H_0	각 자료는 정규분포를 따른다.
H_1	각 자료는 정규분포를 따르지 않는다.

◆ 확인 방법

- ✓ Shapiro-Wilk tests

◆ 가정 위반 시, Wilcoxon Signed-Ranks Test를 진행

04. 가설 검정 기법 - 대응표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 대응표본 t-검정

- ✓ 실험 전후의 차이를 나타내는 데이터는 정규분포를 이룬다.

```
1 : from scipy import stats
2 : t_score, p_value = stats.ttest_rel(df['before_spr'], df['after_spr'])
3 : print(round(t_score, 4), round(p_value, 2))
14.8933 0.0
```

◆ 메서드 설명

- ✓ 이 검정은 두 독립 샘플의 평균(예상) 값이 동일하다는 귀무가설에 대한 검정.
- ✓ 두 집단의 분산이 동일하다고 가정함.

메서드	매개변수	설명
<code>ttest_rel(a, b)</code>	<code>a, b :</code> <code>array_like</code>	데이터의 크기가 동일해야 함.
	<code>alternative</code>	option : two-sided(default), less, greater

- 98 -

$p_value = 0.0 \rightarrow$ 대립가설 채택 $\rightarrow$ 실험 전후 차이가 있음

05. 적합도 검정(goodness-of-fit) : χ^2 검정 (카이제곱검정)

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 어떤 실험에서 관측도수가 가정하는 이론상의 분포를 잘 따른다는 귀무가설을 검정하는 것
- ✓ 관측도수란, 실제 실험에서 단일 특성에 의해 분류된 각 범주의 관측값을 말함
- ✓ 관측도수가 얼마나 이론상의 분포 또는 주어진 형태를 잘 따르는지를 검정하는 가설 검정 기법을 적합도 검정
- ✓ 예) 우리나라 성인의 키가 평균 μ 와 분산 σ^2 을 갖는 정규분포 $N(\mu, \sigma^2)$ 을 따른다고 가정했을 때, 이 가정이 적합한지 검정

가설	설명
H_0	성인의 키는 정규분포 $N(\mu, \sigma^2)$ 를 따른다.
H_1	성인의 키는 정규분포 $N(\mu, \sigma^2)$ 를 따르지 않는다.

◆ 검정통계량

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \quad \begin{array}{l} O_i: \text{관측값} \\ E_i: \text{기대값} \end{array}$$

- 빈도수를 가지고 검정
- 관측도수(count)가 가정하는 이론상의 분포를 잘 따르는 지 검정
- ex) 갤럭시 vs 아이폰
 - 기존에 알려진 시장 점유율 → 7:3
 - 설문조사 실시 → 5:5
 - ⇒ 기존과 실체가 다를 경우
 - 만약 설문조사 실시 → 68:32 의 경우
 - ⇒ 애매함 → 통계검정 실시


05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 어떤 실험에서 관측도수가 가정하는 이론상의 분포를 잘 따른다는 귀무가설을 검정하는 것
- ✓ 관측도수란, 실제 실험에서 단일 특성에 의해 분류된 각 범주의 관측값을 말함
- ✓ 관측도수가 얼마나 이론상의 분포 또는 주어진 형태를 잘 따르는지를 검정하는 가설 검정 기법을 적합도 검정
- ✓ 예) 우리나라 성인의 키가 평균 μ 와 분산 σ^2 을 갖는 정규분포 $N(\mu, \sigma^2)$ 을 따른다고 가정했을 때, 이 가정이 적합한지 검정
- ✓ 예) 트럼프카드의 확률게임

Label	Index i	math.symbol	the value
hearts ♥	0	O_1	64
diamonds ♦	1	O_2	51
spades ♠	2	O_3	50
clubs ♣	3	O_4	35



<출처> <https://ethanweed.github.io/pythontbook/05.01-chisquare.html>

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 어떤 실험에서 관측도수가 가정하는 이론상의 분포를 잘 따른다는 귀무가설을 검정하는 것
- ✓ 관측도수란, 실제 실험에서 단일 특성에 의해 분류된 각 범주의 관측값을 말함
- ✓ 관측도수가 얼마나 이론상의 분포 또는 주어진 형태를 잘 따르는지를 검정하는 가설 검정 기법을 적합도 검정
- ✓ 예) 우리나라 성인의 키가 평균 μ 와 분산 σ^2 을 갖는 정규분포 $N(\mu, \sigma^2)$ 을 따른다고 가정했을 때, 이 가정이 적합한지 검정
- ✓ 예) 트럼프카드의 확률게임

가설	표현식	설명
H_0	$P = (.25, .25, .25, .25)$	모든 경우의 수는 동일하게 같은 확률값으로 선택하게 된다.
H_1	$P \neq (.25, .25, .25, .25)$	적어도 하나는 같은 확률값으로 선택하는 건 아니다

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 검정통계량

- ✓ 예) 트럼프카드의 확률게임

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

O_i : 관측값
 E_i : 기대값

Label	Index i	math	관측값	기대 확률값	기대 빈도(E_i) (N=200)	차이값	제곱값	χ^2 통계량
hearts ♡	0	O_1	64	.25	50	14	196	$196/50 = 3.92$
diamonds ◇	1	O_2	51	.25	50	1	1	$1/50 = 0.02$
spades ♠	2	O_3	50	.25	50	0	0	$0/50 = 0.00$
clubs ♣	3	O_4	35	.25	50	-15	225	$225/50 = 4.50$

8.44

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 주요 메서드 - 카이제곱 검정

- ✓ 기존 분포와 동일한지 검정

```
1 : from scipy import stats
2 : f_score, p_value = stats.chisquare(observed, f_exp = expected)
3 : print(round(t_value, 4), round(p_value, 2))
16.73 0.0
```

◆ 메서드 설명

- ✓ 카이제곱 검정은 범주형 데이터에 주어진 빈도가 있다는 귀무가설을 테스트.

메서드	매개변수	설명
<code>chisquare(f_obs, f_exp)</code>	<code>f_obs</code> : array_like	각 category에서 관측된 빈도수
	<code>f_exp</code> : array_like	각 category의 비율에 따른 기대 빈도수

06. 독립성 검정 : χ^2 검정

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 두 범주형 변수 또는 특성이 존재할 때 두 특성이 서로 독립인지 여부에 대해 알아보는 검정
- ✓ 한 특성이 다른 특성에 영향을 미치는지 여부에 대하여 알아보는 검정
- ✓ 예) 영화 장르별 간식 구매의 상관성 검정

영화 장르	간식류 구매	간식류 비구매	행의 합계
작업	50	75	125
코미디	125	175	300
가족	90	30	120
공포	45	10	55
열의 합계	310	290	전체 합계 = 600

<출처 : https://www.jmp.com/ko_kr/statistics-knowledge-portal/chi-square-test/chi-square-test-of-independence.html>

- 두 개의 범주형 데이터를 비교

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 가설 검정

가설	설명
H_0	영화 장르와 간식류 구입은 서로 독립적이다.
H_1	영화 장르와 간식류 구입은 서로 독립적인 것은 아니다 (= 상관성이 존재한다)

◆ 검정통계량

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(E_{ij} - O_{ij})^2}{E_{ij}}$$

$$df = (r - 1)(c - 1)$$

◆ 카이제곱 분포표

$$\checkmark \alpha = 0.05, df = (r - 1)(c - 1)$$

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 주요 메서드 - 카이제곱 검정

- ✓ 두 범주형 또는 명목형 변수가 서로 연관이 있는 지 가능성 여부를 확인하는 통계 가설 검정

```
1 : from scipy import stats
2 : result = stats.chi2_contingency([X1, X2, X3])
3 : f_score, p_value = result[0], result[1]
4 : print(round(f_score, 4), round(p_value, 4))
    30.1275 0.0
```

◆ 메서드 설명

- ✓ 분할표(contingency table)에서 변수의 독립성에 대한 카이제곱 검정.

메서드	매개변수	설명
<code>chi2_contingency(observed)</code>	observed : array_like	분할표를 말하며, 표에는 각 범주에서 관찰된 빈도(즉, 발생 횟수)가 포함되어 있습니다. 2차원의 경우, 이 테이블은 종종 "R x C 테이블"로 설명됨

07. 분산분석


- 모수검정
 - t검정
 - 카이제곱 검정
 - 분산분석
 - 회귀분석
- 데이터 분석가 희망하는 사람 → 분산분석, 회귀분석 가장 많이 다룸
→ 향후 공부할 때, 분산분석 + 회귀분석 같이 Set로 공부하기
(why? 수학적 원리가 동일 → 최소제곱법)

07. 분산분석

(2023년 11월 기준)

◆ 두개 이상의 집단에서 그룹 평균 간 차이를 그룹 내 변동에 비교하여 살펴보는 통계분석 방법

- ✓ 집단 내에 분산보다 다른 집단과의 분산이 더 크면 유의하다고 할 수 있다는 개념을 가지고 있음



- 분산분석 : 두 그룹이 아닌 세 그룹 이상 평균 비교
- ex) A,B,C 비교를 아래와 같이(독립표본을 3개로 나눠서) 안하는 이유??
 - A, B 그룹 평균 비교 → 허용 오차 0.05
 - B, C 그룹 평균 비교 → 허용 오차 0.05
 - C, A 그룹 평균 비교 → 허용 오차 0.05
 ⇒ 하나의 케이스를 접할 때 마다 오류값이 생김 (제 1종 오류)
 ⇒ 허용오차가 커지게 됨 ⇒ 따라서 새로운 방식인 "분산 분석" 시행

07. 분산분석

(2023년 11월 기준)

- ◆ 두개 이상의 집단에서 그룹 평균 간 차이를 그룹 내 변동에 비교하여 살펴보는 통계분석 방법
 - ✓ 집단 내에 분산보다 다른 집단과의 분산이 더 크면 유의하다고 할 수 있다는 개념을 가지고 있음

구분	명칭	독립변수 개수	종속변수 개수
단일변량 분산분석	일원배치 분산분석	1개	1개
	이원배치 분산분석	2개	
	다원배치 분산분석	3개 이상	
다변량 분산분석	MANOVA	1개 이상	2개 이상

- $y = ax + b$
 - x가 1 증가할 때마다, y가 변동함
 - x : 독립변수 (설명변수)
 - y : 종속변수 (반응변수)

07. 분산분석

(2023년 11월 기준)

- ◆ 일원배치분산분석 (One-Way ANOVA)
 - ✓ 반응값에 대한 하나의 범주형 변수의 영향을 알아보기 위해 사용되는 검증 방법
 - ✓ 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 된다.
 - ✓ F 검정 통계량을 이용한다.

요인	제곱합	자유도	평균제곱	F-value	P
집단 간	SSB	집단 수 - 1	$\frac{\text{집단 간 제곱합}}{\text{자유도}}$	$\frac{\text{집단 간 평균제곱}}{\text{집단 내 평균제곱}}$	-
집단 내	SSW	자료 수 - 집단 수	$\frac{\text{집단 내 제곱합}}{\text{자유도}}$		-
합계	SST	자료 수 - 1	-		-

- ◆ 용어
 - ✓ SST(Sum of Squares) : 총 변동
 - ✓ SSB(Sum of Squares Between) : 집단 간 변동
 - ✓ SSW(Sum of Squares Within) : 집단 내 변동

- F-통계량 : 위 개념은 회귀분석 공부할 때도 나옴

07. 분산분석

(2023년 11월 기준)

◆ 일원배치분산분석 (One-Way ANOVA)

- ✓ 반응값에 대한 하나의 범주형 변수의 영향을 알아보기 위해 사용되는 검증 방법
- ✓ 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 된다.
- ✓ F 검정 통계량을 이용한다.

◆ 가정

- ✓ 집단의 측정치는 서로 독립적이어야 한다.
- ✓ 각 집단의 데이터를 정규분포를 따른다.
 - 집단별 크기가 25미만이면, 정규성을 체크함
 - 만약, 정규성 가정 위반시, Kruskal-Wallis Test를 사용함
- ✓ 표본 크기가 매우 다를 때, 분산의 동질성을 확인하며, Levene Test를 사용
 - 만약, 등분산 가정이 위반되면 Welch Test를 사용함

07. 분산분석

(2023년 11월 기준)

◆ 일원배치분산분석 (One-Way ANOVA)

- ✓ 반응값에 대한 하나의 범주형 변수의 영향을 알아보기 위해 사용되는 검증 방법
- ✓ 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 된다.
- ✓ F 검정 통계량을 이용한다.

◆ 가설

- ✓ 귀무가설 : K개의 집단 간 평균에는 차이가 없다.
- ✓ 대립가설 : K개의 집단 간 평균이 모두 같다고 할 수 없다.

07. 분산분석

(2023년 11월 기준)

◆ 주요 메서드 - 일원배치분산분석 (One Way ANOVA)

- ✓ 일원 분산 분석은 두 개 이상의 그룹이 동일한 모집단 평균을 가지고 있다는 귀무가설을 테스트.
- ✓ 테스트는 크기가 서로 다른 두 개 이상의 그룹의 샘플에 적용됩니다.

```
1 : from scipy import stats
2 : f_score, p_value = stats.f_oneway(X1, X2, X3)
3 : print(round(f_score, 4), round(p_value, 4))
4 : 49.16 0.0
```

◆ 메서드 설명

- ✓ 일원배치분산분석을 수행하며, 각 sample은 Series 형태, array 형태로 오면 된다.

메서드	매개변수	설명
<code>f_oneway(sample1, ...)</code>	sample1 : array_like	The sample measurements for each group.

- $p_value = 0.0 \rightarrow 0.05$ 보다 작으므로 귀무가설 기각 $\rightarrow$ 대립가설 채택 $\rightarrow$ 평균차이가 있다

07. 분산분석

(2023년 11월 기준)

◆ 주요 메서드 - 일원배치분산분석 (One Way ANOVA)

- ✓ 일원 분산 분석은 두 개 이상의 그룹이 동일한 모집단 평균을 가지고 있다는 귀무가설을 테스트.
- ✓ 테스트는 크기가 서로 다른 두 개 이상의 그룹의 샘플에 적용됩니다.
- ✓ 귀무가설 기각, 대립가설 채택 시, 사후검정을 진행해야 함

◆ 사후검정 파이썬 코드 예시

```
1 : from statsmodels.stats.multicomp import pairwise_tukeyhsd
2 : posthoc = pairwise_tukeyhsd(df['outcome_variables'], df['group'])
3 : print(posthoc.summary())
```

```
Multiple Comparison of Means - Tukey HSD, FWER=0.05
-----
group1    group2    meandiff    p-adj    lower    upper    reject
-----
setosa versicolor    -0.658      0.0    -0.8189   -0.4971     True
setosa virginica     -0.454      0.0    -0.6149   -0.2931     True
versicolor virginica    0.204    0.0088    0.0431    0.3649     True
-----
```

- 분산분석은 귀무가설 기각, 대립가설 채택 시 → 사후검정을 추가로 진행
- 그룹 1과 2의 차이를 비교
- 귀무가설 채택한 경우에는 사후검정할 필요 없음

08. 주요 검정 방법 및 메서드 정리 (scipy 기준)

(2023년 11월 기준)

◆ 모수 통계 가설 검정

검정 방법	메서드	라이브러리 링크
단일표본 T-검정	<code>.ttest_1samp()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_1samp.html
독립표본 T-검정	<code>.ttest_ind()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html
대응표본 T-검정	<code>.ttest_rel()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_rel.html
일원분산분석	<code>.f_oneway()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f_oneway.html
카이제곱검정(적합도 검정)	<code>.chisquare()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chisquare.html
카이제곱검정(독립성 검정)	<code>.chi2_contingency()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

◆ 모수 통계 가설 검정

검정 방법	메서드	라이브러리 링크
정규성 검정	<code>.shapiro()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.shapiro.html
등분산성 검정	<code>.levene()</code>	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.levene.html


09. 회귀분석

09. 회귀분석

(2023년 11월 기준)

◆ 기본 개념

✓ 일반적으로 하나의 종속변수 Y 와 여러 독립(=예측)변수 간의 관계를 모델링하는데 사용됨



- 처음부터 빨간색 선이 그어지는 것이 아니라,
처음에 데이터를 그은 후 (1) 그 수식을 기반으로 분산 오차를 구함 → 오차 1만
그 후 모델 2 선을 긋고 오차를 구함 → 오차 5천
계속해서 선을 그어서 오차를 구함
⇒ 최소제곱법

▼ 최소제곱법 수학적 증명 (제미나이)

최소제곱법(Method of Least Squares)은 데이터 점들의 분포를 가장 잘 설명하는 직선(또는 곡선)을 구하는 수학적 방법입니다. 쉽게 말해, "실제 데이터 값과 예측값의 차이(오차)를 제곱해서 더한 뒤, 이를 최소로 만드는 선을 찾는 것"이죠.

가장 기본적이고 직관적인 단순 선형 회귀($y = ax + b$)를 기준으로 수학적 증명을 가장 쉽게 풀어드리겠습니다.

1. 목적 세우기 (오차 정의)

우리가 찾고 싶은 직선의 방정식을 다음과 같다고 해봅시다.

$$y = ax + b$$

데이터 점이 총 n 개 $((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$ 있을 때, 임의의 점 x_i 에 대한 실제 값은 y_i 이고, 직선이 예측한 값은 $ax_i + b$ 입니다.

이때 오차(Error)는 다음과 같습니다.

$$\text{오차} = y_i - (ax_i + b)$$

오차가 양수일 수도 있고 음수일 수도 있으므로, 이들을 단순히 더하면 서로 상쇄되어 버립니다. 그래서 오차를 **제곱**하여 모두 더한 오차 제곱합(E)을 최소화하는 것이 목표입니다.

$$E = \sum_{i=1}^n (y_i - (ax_i + b))^2$$

2. 미분을 이용한 최솟값 찾기

우리의 목표는 E 를 최소로 만드는 a (기울기)와 b (y절편)를 찾는 것입니다. 고등학교 수학에서 함수의 최솟값을 찾을 때 미분해서 0이 되는 지점을 찾았던 것과 같은 원리입니다.

변수가 a 와 b 두 개이므로, 각각에 대해 **편미분**(하나를 상수로 취급하고 미분)하여 0이 되는 식을 세웁니다.

① b 에 대해 편미분하기

E 를 b 에 대해 미분합니다. 곱미분과 속미분의 원리를 이용합니다.

$$\frac{\partial E}{\partial b} = \sum_{i=1}^n 2(y_i - ax_i - b) \cdot (-1) = 0$$

양변을 -2 로 나누어 정리하면:

$$\sum_{i=1}^n (y_i - ax_i - b) = 0$$

이를 시그마($\sum$) 기호에 따라 각각 분리합니다. (참고: $\sum_{i=1}^n b = nb$)

$$\sum_{i=1}^n y_i - a \sum_{i=1}^n x_i - nb = 0$$

양변을 데이터 개수 n 으로 나누면 평균($\bar{x}$, $\bar{y}$)의 형태가 나옵니다.

$$\bar{y} - a\bar{x} - b = 0 \implies b = \bar{y} - a\bar{x}$$

 **첫 번째 수확:** 최적의 직선은 항상 데이터의 평균점 $(\bar{x}, \bar{y})$ 을 지납니다!

② a 에 대해 편미분하기

이번에는 E 를 a 에 대해 미분합니다.

$$\frac{\partial E}{\partial a} = \sum_{i=1}^n 2(y_i - ax_i - b) \cdot (-x_i) = 0$$

양변을 -2 로 나누고 x_i 를 괄호 안에 전개합니다.

$$\sum_{i=1}^n (x_i y_i - ax_i^2 - bx_i) = 0$$

여기에 방금 구한 $b = \bar{y} - a\bar{x}$ 를 대입합니다.

$$\sum_{i=1}^n (x_i y_i - ax_i^2 - (\bar{y} - a\bar{x})x_i) = 0$$

$$\sum_{i=1}^n (x_i y_i - a x_i^2 - \bar{y} x_i + a \bar{x} x_i) = 0$$

\$a\$가 있는 항과 없는 항으로 묶어서 정리합니다.

$$\sum_{i=1}^n (x_i y_i - \bar{y} x_i) - a \sum_{i=1}^n (x_i^2 - \bar{x} x_i) = 0$$

따라서 기울기 \$a\$는 다음과 같이 정리됩니다.

$$a = \frac{\sum_{i=1}^n (x_i y_i - \bar{y} x_i)}{\sum_{i=1}^n (x_i^2 - \bar{x} x_i)}$$

3. 보기 좋게 식 다듬기 (최종 공식)

수학자들이 이 식을 더 직관적으로 만들기 위해 통계학의 **공분산**과 **분산**의 형태로 변형했습니다. (시그마의 성질을 이용해 평균을 빼주는 식으로 변형해도 결과는 같습니다.)

최종적으로 우리가 얻게 되는 최적의 \$a\$와 \$b\$는 다음과 같습니다.

$$a = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{x \text{와 } y \text{의 공분산}}{x \text{의 분산}}$$

$$b = \bar{y} - a \bar{x}$$

요약하자면

1. 오차의 제곱합 식을 만든다.
2. 그래프의 가장 아래쪽(최솟값)을 찾기 위해 \$a\$와 \$b\$로 각각 미분하여 0이 되는 방정식을 푼다.
3. 그 결과, \$x\$의 편차 제곱합 분의 \$x, y\$의 편차 곱의 합이라는 깔끔한 **기울기 (\$a\$) 공식**이 유도된다.

09. 회귀분석

(2023년 11월 기준)

◆ 선형 회귀 모형 진단

- ✓ 회귀 모형이 적합하려면, 4가지 가정을 모두 만족시켜야 함
- ✓ 예측값과 실제 값의 차이인 잔차(Residual)를 이용하여 검증

가정	의미	진단 방법
선형성	종속변수는 독립변수의 선형 함수	잔차 산점도 : 선형성 확인
독립성	독립변수 사이에는 상관관계가 없어야 함	잔차 산점도 : 특정한 경향성이 없어야 함 더빈-왓슨 검정(Durbin-Watson Test)
등분산성	오차항의 분산은 등분산임	잔차 산점도 : 고르게 분포되어야 함
정규성	오차항의 평균은 0임	Shapiro Wilk 검정 Kolmogorov-Smirnov Goodness of Fit Test Q-Q plot

◆ 검정 설명

- ✓ Shapiro Wilk 검정 : 데이터의 정규성을 검증하는 방법
- ✓ Kolmogorov-Smirnov 검정 : 데이터가 예상되는 분포에 얼마나 잘 맞는지를 검정

- 검정을 다통과해야 회귀분석 가능
 - 회귀분석의 귀무가설, 대립가설
 $y = ax + b$ (1차방정식)
 - 귀무가설 : a 의 기울기가 0이다
 - 대립가설 : a 의 기울기가 0이 아니다
- => 최소제곱법에 의해 기울기, 절편이 나옴

ADsP 강의_슬라이드_2025.pdf 126-133p.

제1과목 — 제2과목 — 제3과목
데이터분석

III. 정형 데이터마이닝
03 분류 분석 - 로지스틱 회귀분석

개요

- 반응변수가 범주형인 경우에 적용되는 회귀분석모형
- 새로운 설명변수(또는 예측변수)가 주어질 때 반응변수의 각 범주(또는 집단)에 속할 확률이 얼마인지를 추정(예측모형)하여, 추정 확률을 기준치에 따라 분류하는 목적(분류모형)으로 활용됨.
- 어떤 사건(Event)이 발생할 지에 대한 직접 예측이 아닌 그 사건이 발생할 확률을 예측함.
- 이때 모형의 적합을 통해 추정된 확률을 사후확률(Posterior Probability)이라고 함

정의



- $p = P(\text{성공} | k\text{개의 독립변수}), k\text{개의 독립변수가 주어졌을 때의 1인 확률}$
- $1 - p = P(\text{실패} | k\text{개의 독립변수}), k\text{개의 독립변수가 주어졌을 때의 0인 확률}$
- 예측된 확률에 따라 가능성이 더 높은 범주로 분류하는 지도학습 기반의 알고리즘으로 정리할 수 있음.

제1과목 — 제2과목 — 제3과목
데이터분석

III. 정형 데이터마이닝
03 분류 분석 - 로지스틱 회귀분석

원리

- 종속변수 Y 가 범주형 변수일 경우, 일반적인 선형회귀모델로는 범주값을 추정할 수 없음. 이유는 종속변수 Y 는 1과 0으로 이루어져 있고, 선형회귀모델은 (-)무한대에서 (+)무한대($-\infty, \infty$) 사이의 값을 가지기 때문임.
- 따라서 독립변수가 (-)무한대에서 (+)무한대($-\infty, \infty$)에 포함되는 어떤 숫자이든 상관없이 종속변수값이 항상 $[0, 1]$ 사이의 범위에 있도록 하거나, 범주형 변수를 (-)무한대에서 (+)무한대의 값으로 변환해 주어야 함
- 이 과정은 오즈(odds)를 로짓(Logit) 변환함으로써 정의할 수 있는 로지스틱함수(Logistic Function)를 이용하여 변환함.

- 직선을 곡선으로 변형시켜서 오차를 줄여줌
- 조건 : 로짓변환 → 0과 1 사이에 여러 실수들이 등장

III. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

Odds 정의

- 오즈는 어떤 사건이 일어날 확률을 그 사건이 일어나지 않을 확률로 나눈 값이며, 특정 사건이 발생할 확률에 대한 그 사건이 발생하지 않을 확률의 비율을 의미함.
- 종속변수 Y가 성공(1)일 때, 오즈의 값의 범위는 다음 식으로 표현되며, 오즈는 0에서 (+)무한대(0, ∞) 사이의 값을 가지게 한다.


$$Odds(Y=1) = \frac{p}{1-p} \cdot p: (y=1|x)$$

$$0 \leq \text{오즈}(Odds) \leq \infty$$

x : 독립변수, y : 종속변수

제1과목 — 제2과목 — 제3과목

데이터분석



- Odds
ex) 우리가 이길 확률 / 질 확률

III. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

오즈비 계산

- 오즈비(Odds)는 성공할 확률이 실패할 확률의 몇 배인지를 나타내는 확률이며, 오즈비는 두 오즈의 비율임
- 2018년 한국과 독일이 월드컵 16강에 진출을 성공/실패할 확률과 각각의 오즈와 오즈비는 다음과 같음

제1과목 — 제2과목 — 제3과목

데이터분석

구분	16강 성공 확률	16강 실패 확률	Odds	Odds Ratio
독일	0.8	0.2	$\frac{0.8}{(1-0.8)} = \frac{0.8}{0.2} = 4$	$\frac{odds(독일)}{odds(한국)} = \frac{4}{1/9} = 36$
한국	0.1	0.9	$\frac{0.1}{(1-0.1)} = \frac{0.1}{0.9} = \frac{1}{9}$	

- 오즈비가 36으로 나타나 독일이 16강에 진출할 확률이 한국의 16강 진출 확률보다 36배 높다고 할 수 있음