

03 분류 분석 – 로지스틱 회귀분석

개요

- 반응변수가 범주형인 경우에 적용되는 회귀분석모형
- 새로운 설명변수(또는 예측변수)가 주어질 때 반응변수의 각 범주(또는 집단)에 속할 확률이 얼마인지를 추정(예측모형)하여, 추정 확률을 기준치에 따라 분류하는 목적(분류모형)으로 활용됨.
- 어떤 사건(Event)이 발생할 지에 대한 직접 예측이 아닌 그 사건이 발생할 확률을 예측함.
- 이때 모형의 적합을 통해 추정된 확률을 사후확률(Posterior Probability)이라고 함

정의



- $p = P(\text{성공} | k\text{개의 독립변수}), k\text{개의 독립변수가 주어졌을 때의 1인 확률}$
- $1 - p = P(\text{실패} | k\text{개의 독립변수}), k\text{개의 독립변수가 주어졌을 때의 0인 확률}$
- 예측된 확률에 따라 가능성이 더 높은 범주로 분류하는 지도학습 기반의 알고리즘으로 정리할 수 있음.

Ⅲ. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

원리

- 종속변수 Y 가 범주형 변수일 경우, 일반적인 선형회귀모델로는 범주값을 추정할 수 없음. 이유는 종속변수 Y 는 1과 0으로 이루어져 있고, 선형회귀모델은 $(-)$ 무한대에서 $(+)$ 무한대 $(-\infty, \infty)$ 사이의 값을 가지기 때문임.
- 따라서 독립변수가 $(-)$ 무한대에서 $(+)$ 무한대 $(-\infty, \infty)$ 에 포함되는 어떤 숫자이든 상관없이 종속변수값이 항상 $[0, 1]$ 사이의 범위에 있도록 하거나, 범주형 변수를 $(-)$ 무한대에서 $(+)$ 무한대의 값으로 변환해 주어야 함
- 이 과정은 오즈(odds)를 로짓(Logit) 변환함으로써 정의할 수 있는 로지스틱함수(Logistic Function)를 이용하여 변환함.



Ⅲ. 정형데이터마이닝

03 분류 분석 – 로지스틱 회귀분석


Odds 정의

- 오즈는 어떤 사건이 일어날 확률을 그 사건이 일어나지 않을 확률로 나눈 값이며, 특정 사건이 발생할 확률에 대한 그 사건이 발생하지 않을 확률의 비율을 의미함.
- 종속변수 Y가 성공(1)일 때, 오즈의 값의 범위는 다음 식으로 표현되며, 오즈는 0에서 (+)무한대($0, \infty$) 사이의 값을 가지게 한다.

$$Odds(Y = 1) = \frac{p}{1-p}, p: (y = 1|x)$$

$$0 \leq \text{오즈}(Odds) \leq \infty$$

x : 독립변수, y : 종속변수



III. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

Logit 정의

- 로짓은 오즈에 로그를 취한 값으로, 오즈의 비대칭성을 대칭으로 변환해주는 과정으로 정의
- 오즈의 0의 값을 무한대 값으로 변환하여 (-)무한대에서 (+)무한대($-\infty, \infty$) 사이의 값을 가지게 하며, 범주형 종속변수를 로짓변환하면 선형회귀식으로 종속 변수 Y 에 대한 값을 추정할 수 있게 됨.
- 수식

$$Odds(Y = 1) = \frac{p}{1-p}, p: (y = 1|x)$$

$$0 \leq \text{오즈}(Odds) \leq \infty$$

x : 독립변수, y : 종속변수

$$Logit(p) = Log(odds) = \log \frac{p(X)}{1-p(X)}$$

$$= \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

$$-\infty \leq \text{로그오즈}(Log Odds) \leq \infty$$

03 분류 분석 - 로지스틱 회귀분석

로지스틱함수(Logistic Function) 정의

- 로지스틱함수는 로짓(Logit)의 역함수이다. 즉, 음의 무한대부터 양의 무한대까지의 값을 가지는 입력변수를 0부터 1사이의 값을 가지는 출력변수로 변환하는 역할을 한다.

- 수식

$$\begin{aligned} \text{Logit}(p) &= \text{Log(odds)} = \log \frac{p(X)}{1-p(X)} \\ &= \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k \\ -\infty &\leq \text{로그오즈(Log Odds)} \leq \infty \end{aligned}$$

$$\begin{aligned} \text{Logit}(p)^{-1}(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k) &= \frac{1}{1 + \exp^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}} \\ \text{Logit}(p)^{-1}(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k) &= \text{Logistic}(z) = \frac{1}{1 + \exp^{-z}} \end{aligned}$$


$$0 \leq \text{성공확률}(P) \leq 1$$

Ⅲ. 정형데이터마이닝

03 분류 분석 - 로지스틱 회귀분석

로지스틱함수(Logistic Function) 정의

- 로지스틱함수는 로짓(Logit)의 역함수이다. 즉, 음의 무한대부터 양의 무한대까지의 값을 가지는 입력변수를 0부터 1사이의 값을 가지는 출력변수로 변환하는 역할을 한다.
- 로지스틱함수는 연결함수(Link Function)의 한 종류인 시그모이드함수(Sigmoid Function)와 동의어임을 기억하자.
- 로지스틱회귀분석 결과로 나온 각 클래스의 확률은 분류를 목적으로 할 경우 0.5를 임계값으로 사용하여 0.5보다 크면 성공(1). 0.5보다 작으면 실패(0)으로 분류할 수 있다.



03 분류 분석 – 로지스틱 회귀분석

로지스틱회귀분석의 적합성검정

- 선형회귀분석과 로지스틱회귀분석의 회귀계수 추정방법과 적합성검정방법 차이는 다음과 같다.

구분	선형회귀분석	로지스틱회귀분석
목적	연속형 종속변수값 예측	비연속형 종속변수값 범주 예측
회귀계수 추정	최소제곱법	최대가능도(우도) 추정법
회귀계수, 유의성검정	t 검정	왈드(Wald) 통계량
모델 적합도	분산분석(F 검정)	호스머 레믹소, 적합도검정(카이제곱검정 사용)
모델 설명력	결정계수(R^2), 수정된 결정계수(Adjust R^2)	로그우도함수 $\log(L)=LL$ 맥파든 의사결정계수(R^2_{pseudo})

Ⅲ. 정형데이터마이닝

03 분류 분석 – 로지스틱 회귀분석

오즈비 계산

- 오즈비(Odds)는 성공할 확률이 실패할 확률의 몇 배인지를 나타내는 확률이며, 오즈비는 두 오즈의 비율임
- 2018년 한국과 독일이 월드컵 16강에 진출을 성공/실패할 확률과 각각의 오즈와 오즈비는 다음과 같음

구분	16강 성공 확률	16강 실패 확률	Odds	Odds Ratio
독일	0.8	0.2	$\frac{0.8}{(1 - 0.8)} = \frac{0.8}{0.2} = 4$	$\frac{odds(독일)}{odds(한국)} = \frac{4}{1/9} = 36$
한국	0.1	0.9	$\frac{0.1}{(1 - 0.1)} = \frac{0.1}{0.9} = \frac{1}{9}$	

- 오즈비가 36으로 나타나 독일이 16강에 진출할 확률이 한국의 16강 진출 확률보다 36배 높다고 할 수 있음