

작업형 제3유형

with  python™

◆ 가설 (Hypothesis)

✓ 모집단의 특성, 특히 모수에 대한 가정 혹은 잠정적인 결론이다.

종류	설명
귀무가설 (H_0 , Null Hypothesis)	- 기존과 비교하여 변화 혹은 차이가 없음을 나타내는 가설 - 검정 방법에 따라 귀무가설의 내용이 달라짐
대립가설 (H_1 , Alternative Hypothesis)	- 표본을 통해 확실한 근거를 가지고 입증하고자 하는 가설 - 연구가설 (Research Hypothesis) 이라고도 함

◆ 가설 검정 시, 관심 있는 가설은 대립가설이며, 대립가설이 참이라는 확실한 근거가 없다면 귀무가설 채택

- ✓ 표현문구는 귀무가설 채택 (X), **귀무가설을 기각하지 못한다 (O)**
- ✓ 대립가설이 참이라는 확실한 근거 발견 시, **귀무가설을 기각한다(O)** 표현

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ 가설 검정

- ✓ 단계 1. 모집단에 대해 어떤 가설 설정
- ✓ 단계 2. 모집단으로부터 추출된 표본 분석
- ✓ 단계 3. 연구 가설이 틀린지 맞는지 타당성 여부를 검정하는 통계적 기법

◆ 검정통계량


- ✓ 모수 추론하기 위해 필요한 표본 통계량
- ✓ 귀무가설이 참이라는 전제하에 추출된 확률표본의 정보를 이용하여 계산함
- ✓ 중심극한정리 이론에 근거하기 때문에, 적은 표본으로도 전체 모수를 추정할 수 있음

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ 중심 극한 정리(CLT : Central Limit Theorem)

- ✓ 정의 : 정규분포가 아닌 분포라도 선택된 표본들의 평균을 모아 다시 분포를 그리면 정규분포가 됨
- ✓ 단, 최소 표본의 크기가 작으면 안됨 ($n \geq 30$)
- ✓ CLT에 따르면, Sampling Distribution은 정규분포를 따름
- ✓ 모든 모집단 데이터의 평균 = 모든 샘플 평균들의 평균 = Sampling Distribution의 평균



출처 : <https://corporatefinanceinstitute.com/resources/data-science/central-limit-theorem/>

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ 가설 검정 오류

✓ 다음과 같은 통계적 오류가 발생할 가능성이 항상 존재함

	귀무가설(H_0)이 사실이라고 판정 (무죄)	귀무가설(H_0)이 거짓이라고 판정 (유죄)
귀무가설(H_0)이 사실	옳은 결정 No Error ($1-\alpha$) 무죄를 무죄라 함	제1종 오류 무죄를 유죄라 함
귀무가설(H_0)이 거짓	제2종 오류 유죄를 무죄라 함	옳은 결정 No Error ($1-\beta$) 유죄를 유죄라 함

◆ 가설 검정 오류

✓ 다음과 같은 통계적 오류가 발생할 가능성이 항상 존재함

종류	설명
제 1종 오류 (Type I Error)	- 귀무가설이 참이나 귀무가설을 기각하는 오류 - 유의수준(Level of Significance) - 제 1종 오류를 범할 최대 허용확률 α로 표기하며, 일반적으로 α값을 0.01, 0.05 또는 0.1 등의 값으로 설정 - 신뢰수준(Level of Confidence) - 귀무가설이 참일 때 이를 참이라고 판단하는 확률 $1 - \alpha$로 표기함
제 2종 오류 (Type II Error)	- 귀무가설이 참이 아닌데, 귀무가설을 채택하는 경우 - 베타수준(β) - 제2종 오류를 범할 최대 허용확률 - 검정력 - 귀무가설이 참이 아닌 경우 이를 기각할 수 있는 확률 $1 - \beta$로 표기함

- ◆ 의사 결정의 원칙
 - ✓ 귀무가설이 옳다는 가정하에 H_1 이 옳다는 증거를 제시해야 함 (Presumed Innocence)
- ◆ 의사 결정의 기준
 - ✓ 가장 주의해야 하는 것은 1종 오류를 범하는 것
 - 나의 주장이 옳지 않은데 옳다고 결론 내리는 것
 - ✓ 의사결정의 기준은 1종 오류를 범할 확률(유의 수준 α)


	의사결정	설명
$\alpha = 0$	H_0	무죄인 사람을 유죄라고 판단 할 오류 0%
$\alpha = 0.01$ (1%)	H_0 : 99% H_1 : 1%	매우 보수적이며 엄격한 판단 표본에서 구한 통계량 값이 나올 확률이 1%보다 작을 때 의미
$\alpha = 0.05$ (5%)	H_0 : 95% H_1 : 5%	오류가 5%까지 허용 상대적으로 덜 엄격한 의사결정

01. 가설 검정 주요 용어

(2023년 11월 기준)

◆ p-value와 임계값

- ✓ 귀무가설 H_0 가 참일 때 표본에서 얻어진 결과가 귀무가설을 기각하게 하는 확률
- ✓ 주어진 유의수준 α 하에서 귀무가설 H_0 의 채택 또는 기각 여부를 판정하여 주는 기준이 되는 값



◆ p-value와 임계값

- ✓ 귀무가설 H_0 가 참일 때 표본에서 얻어진 결과가 귀무가설을 기각하게 하는 확률
- ✓ 주어진 유의수준 α 하에서 귀무가설 H_0 의 채택 또는 기각 여부를 판정하여 주는 기준이 되는 값

p-value	Sig. stars	해석	귀무가설
$p > 0.05$		통계적으로 유의하지 않음	채택(Retained)
$p < 0.05$	*	통계적으로 유의함($\alpha = 0.05$)	기각(Rejected)
$p < 0.01$	**	통계적으로 유의함($\alpha = 0.01$)	기각(Rejected)
$p < 0.001$	***	통계적으로 유의함($\alpha = 0.001$)	기각(Rejected)

02. 가설 검정 기법 - 단일표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 모평균 μ 에 대한 검정 절차로 다음과 같이 귀무가설과 대립가설 설정

가설	표현식	설명
H_0	$\mu = \mu_0$	모평균과 표본평균은 같다
H_1	$\mu \neq \mu_0$	모평균과 표본평균은 같지 않다.

◆ 검정통계량

- ✓ 모분산을 알고 있을 때,

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$$

$\bar{X}$: 표본평균

σ : 모분산

n : 표본의 갯수

02. 가설 검정 기법 - 단일표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 실습

- ✓ 모평균의 값을 알고 있을 때

```
1 : from scipy import stats
2 : t_score, p_value = stats.ttest_1samp(df['Height'], popmean=75)
3 : print(round(t_score, 2), round(p_value, 2))
    0.87, 0.39
```

◆ 메서드 설명

- ✓ 독립 관측치 샘플 array의 예상값(평균)이 주어진 모집단 평균인 popmean과 같다는 귀무 가설에 대한 검정.

메서드	매개변수	설명
ttest_1samp(array, popmean)	array	Sample Observation
	popmean	Expected value in null hypothesis

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 두개의 독립 표본 X, Y 가 각각 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 를 따를 때, 두 모집단의 평균 차이 $\mu_1 - \mu_2$ 의 검정은 다음과 같음.

가설	표현식	설명
H_0	$\mu_1 = \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같다.
H_1	$\mu_1 \neq \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같지 않다.

◆ 가정(Assumptions) 확인

- ✓ 독립성
- ✓ Normality 정규성
- ✓ Homogeneity of Variance 분산의 동질성

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 정규성 검정

- ✓ 각 그룹의 표본수가 $N \leq 30$ 이하일 때, 검정해야 함
- ✓ 각 그룹의 표본수가 모두 $N \geq 30$ 이상일 때, 중심극한정리에 의해 정규성 가정을 만족했다고 봄

가설	설명
H_0	각 자료는 정규분포를 따른다.
H_1	각 자료는 정규분포를 따르지 않는다.

◆ 확인 방법

- ✓ Shapiro-Wilk tests

◆ 가정 위반 시, Mann-Whitney Test를 진행

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 등분산성 검정

- ✓ 각 그룹의 데이터수가 다르면 분산이 같은지 검정
- ✓ 만약에 각 그룹의 데이터수가 동일하면, 분산이 같다고 가정함

가설	설명
H_0	두 그룹의 분산은 차이가 없음
H_1	두 그룹의 분산은 차이가 있음

◆ 확인 방법

- ✓ bartlett, fligner, levene 검정 주로 사용
- ✓ 일반적으로는 levene 검정을 주로 사용

◆ 가정 위반 시

- ✓ Welch Test 사용

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

✓ 두개의 독립 표본 X, Y 가 각각 $N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ 를 따를 때, 두 모집단의 평균 차이 $\mu_1 - \mu_2$ 의 검정은 다음과 같음.

가설	표현식	설명
H_0	$\mu_1 = \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같다.
H_1	$\mu_1 \neq \mu_2$	그룹 1의 평균과 그룹 2의 평균은 같지 않다.

◆ 검정통계량

- ✓ 그룹 1의 표본평균 $\bar{X}$, 그룹 2의 표본평균 $\bar{Y}$ 의 차이에 근거하여 구성
- ✓ 검정통계량 T 는 자유도 $n + m - 2$ 인 t -분포를 따른다.

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}}, S_p^2 = \frac{(n-1)s_1^2 + (m-1)s_2^2}{n+m-2}$$

S_p^2 : 공통분산 σ^2 의 합동 표본분산
 $n - 1$: 그룹 1 표본의 자유도
 $m - 1$: 그룹 2 표본의 자유도

◆ 주요 메서드 - 등분산성 검정 실습

- ✓ 데이터의 각 변수들은 정규분포를 만족하며, 두 그룹은 등분산을 만족한가?

```
1 : from scipy import stats
2 : stats.levene(df.loc[df['supp'] == "VC", 'len'], df.loc[df['supp'] == "OJ", 'len'])
LeveneResult(statistic=1.2135720656945064, pvalue=0.2751764616144053)
```

◆ 메서드 설명

- ✓ Levene 검정은 모든 입력 샘플이 동일한 분산을 가진 모집단에서 나온 것이라는 귀무가설을 테스트 함

메서드	매개변수	설명
<code>levene(sample1, sample2, ...)</code>	sample1 : array_like	The sample data, possibly with different lengths. Only one-dimensional samples are accepted.

03. 가설 검정 기법 - 독립표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 독립표본 t-검정

- ✓ 데이터의 각 변수들은 정규분포를 만족하며, 두 그룹은 등분산을 만족한다!

```
1 : from scipy import stats
2 : t_score, p_value = stats.ttest_ind(df.loc[df['supp'] == "VC", 'len'],
                                     df.loc[df['supp'] == "OJ", 'len'], equal_var = True)
3 : print(round(t_score, 4), round(p_value, 2))
    -1.9153 0.06
```

◆ 메서드 설명

- ✓ 이 검정은 두 독립 샘플의 평균(예상) 값이 동일하다는 귀무가설에 대한 검정.
- ✓ 두 집단의 분산이 동일하다고 가정함.

메서드	매개변수	설명
ttest_ind(a, b, equal_var)	a, b	데이터의 크기가 동일해야 함.
	equal_var	If true, independent t-test / If false, Welch's t-test

◆ 가설 설정

- ✓ 실험단위를 동질적인 쌍으로 묶은 다음, 각 쌍에서 관측값의 차를 이용하여 두 모평균의 차이에 관한 추론
- ✓ 실험 이전의 집단과 실험 이후의 집단이 동일한 경우 사용하는 검정(쌍체비교)이라고 한다.
- ✓ $(X_1, Y_1), (X_2, Y_2), (X_3, Y_3), \dots, (X_n, Y_n)$
- ✓ 각 쌍의 차이를 $D_i = X_i - Y_i (i = 1, 2, \dots, n)$ 로 정의할 때, D_i 는 $N(\mu_D, \sigma_D^2)$ 으로부터의 확률표본으로 가정한다.
- ✓ $\mu_D = \mu_1 - \mu_2$

가설	표현식	설명
H_0	$\mu_D = 0$	실험전후 평균의 차이는 0이다
H_1	$\mu_D \neq 0$	실험전후 평균의 차이는 0이 아니다

◆ 가정(Assumptions) 확인

- ✓ 독립성
- ✓ 정규성

04. 가설 검정 기법 - 대응표본 T-검정

(2023년 11월 기준)

◆ 정규성 검정

- ✓ 실험전후 두 변수의 차이가 정규분포를 따르는지 확인, $N \leq 30$ 이하일 때, 검정해야 함
- ✓ 각 그룹의 변수가 정규분포를 따르는지는 검정할 필요가 없음
- ✓ 각 그룹의 표본수가 모두 $N \geq 30$ 이상일 때, 중심극한정리에 의해 정규성 가정을 만족했다고 봄

가설	설명
H_0	각 자료는 정규분포를 따른다.
H_1	각 자료는 정규분포를 따르지 않는다.

◆ 확인 방법

- ✓ Shapiro-Wilk tests

◆ 가정 위반 시, Wilcoxon Signed-Ranks Test를 진행

04. 가설 검정 기법 - 대응표본 T-검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 실험단위를 동질적인 쌍으로 묶은 다음, 각 쌍에서 관측값의 차를 이용하여 두 모평균의 차이에 관한 추론
- ✓ 실험 이전의 집단과 실험 이후의 집단이 동일한 경우 사용하는 검정(쌍체비교)이라고 한다.
- ✓ $(X_1, Y_1), (X_2, Y_2), (X_3, Y_3), \dots, (X_n, Y_n)$
- ✓ 각 쌍의 차이를 $D_i = X_i - Y_i (i = 1, 2, \dots, n)$ 로 정의할 때, D_i 는 $N(\mu_D, \sigma_D^2)$ 으로부터의 확률표본으로 가정한다.
 - ✓ $\mu_D = \mu_1 - \mu_2$

가설	표현식	설명
H_0	$\mu_D = 0$	실험전후 평균의 차이는 0이다
H_1	$\mu_D \neq 0$	실험전후 평균의 차이는 0이 아니다

◆ 검정통계량

- ✓ 실험 전 표본평균 X , 실험 후 표본평균 Y 의 차이의 평균(D)에 근거하여 구성

$$t = \frac{D}{s_D / \sqrt{n}} \quad S_D: X \text{와 } Y \text{의 차이에 관한 표준편차}$$

04. 가설 검정 기법 - 대응표본 T-검정

(2023년 11월 기준)

◆ 주요 메서드 - 대응표본 t-검정

- ✓ 실험 전후의 차이를 나타내는 데이터는 정규분포를 이룬다.

```
1 : from scipy import stats
2 : t_score, p_value = stats.ttest_rel(df['before_spr'], df['after_spr'])
3 : print(round(t_score, 4), round(p_value, 2))
    14.8933 0.0
```

◆ 메서드 설명

- ✓ 이 검정은 두 독립 샘플의 평균(예상) 값이 동일하다는 귀무가설에 대한 검정.
- ✓ 두 집단의 분산이 동일하다고 가정함.

메서드	매개변수	설명
<code>ttest_rel(a, b)</code>	<code>a, b :</code> <code>array_like</code>	데이터의 크기가 동일해야 함.
	<code>alternative</code>	<code>option : two-sided(default), less, greather</code>

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 어떤 실험에서 관측도수가 가정하는 이론상의 분포를 잘 따른다는 귀무가설을 검정하는 것
- ✓ 관측도수란, 실제 실험에서 단일 특성에 의해 분류된 각 범주의 관측값을 말함
- ✓ 관측도수가 얼마나 이론상의 분포 또는 주어진 형태를 잘 따르는지를 검정하는 가설 검정 기법을 적합도 검정
- ✓ 예) 우리나라 성인의 키가 평균 μ 와 분산 σ^2 을 갖는 정규분포 $N(\mu, \sigma^2)$ 을 따른다고 가정했을 때, 이 가정이 적합한지 검정

가설	설명
H_0	성인의 키는 정규분포 $N(\mu, \sigma^2)$ 를 따른다.
H_1	성인의 키는 정규분포 $N(\mu, \sigma^2)$ 를 따르지 않는다.

◆ 검정통계량

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

O_i : 관측값
 E_i : 기대값


05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 어떤 실험에서 관측도수가 가정하는 이론상의 분포를 잘 따른다는 귀무가설을 검정하는 것
- ✓ 관측도수란, 실제 실험에서 단일 특성에 의해 분류된 각 범주의 관측값을 말함
- ✓ 관측도수가 얼마나 이론상의 분포 또는 주어진 형태를 잘 따르는지를 검정하는 가설 검정 기법을 적합도 검정
- ✓ 예) 우리나라 성인의 키가 평균 μ 와 분산 σ^2 을 갖는 정규분포 $N(\mu, \sigma^2)$ 을 따른다고 가정했을 때, 이 가정이 적합한지 검정
- ✓ 예) 트럼프카드의 확률게임

Label	Index i	math.symbol	the value
hearts ♥	0	O_1	64
diamonds ♦	1	O_2	51
spades ♠	2	O_3	50
clubs ♣	3	O_4	35



<출처> <https://ethanweed.github.io/pythonbook/05.01-chisquare.html>

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 어떤 실험에서 관측도수가 가정하는 이론상의 분포를 잘 따른다는 귀무가설을 검정하는 것
- ✓ 관측도수란, 실제 실험에서 단일 특성에 의해 분류된 각 범주의 관측값을 말함
- ✓ 관측도수가 얼마나 이론상의 분포 또는 주어진 형태를 잘 따르는지를 검정하는 가설 검정 기법을 적합도 검정
- ✓ 예) 우리나라 성인의 키가 평균 μ 와 분산 σ^2 을 갖는 정규분포 $N(\mu, \sigma^2)$ 을 따른다고 가정했을 때, 이 가정이 적합한지 검정
- ✓ 예) 트럼프카드의 확률게임

가설	표현식	설명
H_0	$P = (.25, .25, .25, .25)$	모든 경우의 수는 동일하게 같은 확률값으로 선택하게 된다.
H_1	$P \neq (.25, .25, .25, .25)$	적어도 하나는 같은 확률값으로 선택하는 건 아니다

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 검정통계량

✓ 예) 트럼프카드의 확률게임

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

O_i : 관측값

E_i : 기대값

Label	Index i	math	관측값	기대 확률값	기대 빈도(E_i) (N=200)	차이값	제곱값	χ^2 통계량
hearts ♡	0	O_1	64	.25	50	14	196	196/50 = 3.92
diamonds ◇	1	O_2	51	.25	50	1	1	1/50 = 0.02
spades ♠	2	O_3	50	.25	50	0	0	0/50 = 0.00
clubs ♣	3	O_4	35	.25	50	-15	225	225/50 = 4.50

8.44

05. 적합도 검정(goodness-of-fit) : χ^2 검정

(2023년 11월 기준)

◆ 주요 메서드 - 카이제곱 검정

- ✓ 기존 분포와 동일한지 검정

```
1 : from scipy import stats
2 : f_score, p_value = stats.chisquare(observed, f_exp = expected)
3 : print(round(t_score, 4), round(p_value, 2))
    16.73 0.0
```

◆ 메서드 설명

- ✓ 카이제곱 검정은 범주형 데이터에 주어진 빈도가 있다는 귀무가설을 테스트.

메서드	매개변수	설명
<code>chisquare(f_obs, f_exp)</code>	<code>f_obs</code> : array_like	각 category에서 관측된 빈도수
	<code>f_exp</code> : array_like	각 category의 비율에 따른 기대 빈도수

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 가설 설정

- ✓ 두 범주형 변수 또는 특성이 존재할 때 두 특성이 서로 독립인지 여부에 대해 알아보는 검정
- ✓ 한 특성이 다른 특성에 영향을 미치는지 여부에 대하여 알아보는 검정
- ✓ 예) 영화 장르별 간식 구매의 상관성 검정

영화 장르	간식류 구매	간식류 비구매	행의 합계
작업	50	75	125
코미디	125	175	300
가족	90	30	120
공포	45	10	55
열의 합계	310	290	전체 합계 = 600

<출처 : https://www.jmp.com/ko_kr/statistics-knowledge-portal/chi-square-test/chi-square-test-of-independence.html>

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 가설 검정

가설	설명
H_0	영화 장르와 간식류 구입은 서로 독립적이다.
H_1	영화 장르와 간식류 구입은 서로 독립적인 것은 아니다 (= 상관성이 존재한다)

◆ 검정통계량

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(E_{ij} - O_{ij})^2}{E_{ij}}$$

$$df = (r - 1)(c - 1)$$

◆ 카이제곱 분포표

$$\checkmark \alpha = 0.05, df = (r - 1)(c - 1)$$

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)


◆ 카이제곱 분포표

✓ $\alpha = 0.05, df = (r - 1)(c - 1)$

◆ χ^2 와 카이제곱 분포표와 비교

✓ $\chi^2 > \text{카이제곱 분포표} : H_0 \text{ 기각}$

✓ $\chi^2 < \text{카이제곱 분포표} : H_0 \text{ 채택}$



Degree of Freedom	Probability of Exceeding the Critical Value								
	0.99	0.95	0.90	0.75	0.50	0.25	0.10	0.05	0.01
1	0.000	0.004	0.016	0.102	0.455	1.32	2.71	3.84	6.63
2	0.020	0.103	0.211	0.575	1.386	2.77	4.61	5.99	9.21
3	0.115	0.352	0.584	1.212	2.366	4.11	6.25	7.81	11.34
4	0.297	0.711	1.064	1.923	3.357	5.39	7.78	9.49	13.28
5	0.554	1.145	1.610	2.675	4.351	6.63	9.24	11.07	15.09
6	0.872	1.635	2.204	3.455	5.348	7.84	10.64	12.59	16.81
7	1.239	2.167	2.833	4.255	6.346	9.04	12.02	14.07	18.48
8	1.647	2.733	3.490	5.071	7.344	10.22	13.36	15.51	20.09
9	2.088	3.325	4.168	5.899	8.343	11.39	14.68	16.92	21.67
10	2.558	3.940	4.865	6.737	9.342	12.55	15.99	18.31	23.21
11	3.053	4.575	5.578	7.584	10.341	13.70	17.28	19.68	24.72
12	3.571	5.226	6.304	8.438	11.340	14.85	18.55	21.03	26.22
13	4.107	5.892	7.042	9.299	12.340	15.98	19.81	22.36	27.69
14	4.660	6.571	7.790	10.165	13.339	17.12	21.06	23.68	29.14
15	5.229	7.261	8.547	11.037	14.339	18.25	22.31	25.00	30.58
16	5.812	7.962	9.312	11.912	15.338	19.37	23.54	26.30	32.00
17	6.408	8.672	10.085	12.792	16.338	20.49	24.77	27.59	33.41
18	7.015	9.390	10.865	13.675	17.338	21.60	25.99	28.87	34.80
19	7.633	10.117	11.651	14.562	18.338	22.72	27.20	30.14	36.19
20	8.260	10.851	12.443	15.452	19.337	23.83	28.41	31.41	37.57
22	9.542	12.338	14.041	17.240	21.337	26.04	30.81	33.92	40.29
24	10.856	13.848	15.659	19.037	23.337	28.24	33.20	36.42	42.98
26	12.198	15.379	17.292	20.843	25.336	30.43	35.56	38.89	45.64
28	13.565	16.928	18.939	22.657	27.336	32.62	37.92	41.34	48.28
30	14.953	18.493	20.599	24.478	29.336	34.80	40.26	43.77	50.89
40	22.164	26.509	29.051	33.660	39.335	45.62	51.80	55.76	63.69
50	27.707	34.764	37.689	42.942	49.335	56.33	63.17	67.50	76.15
60	37.485	43.188	46.459	52.294	59.335	66.98	74.40	79.08	88.38
Not Significant								Significant	

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 각 셀의 기대도수 계산

영화 장르	간식류 구매	간식류 비구매	행의 합계
작업	50 $125 \times 310 / 600 = 64.58$	75 $125 \times 290 / 600 = 60.42$	125
코미디	125 155	175 145	300
가족	90 62	30 58	120
공포	45 28.42	10 26.58	55
열의 합계	310	290	전체 합계 = 600

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 각 셀의 **검정통계량** 계산

영화 장르	간식류 구매	간식류 비구매	행의 합계
작업	차이 $50 - 64.58 = -14.58$ 제곱값 : 212.67 기대값으로 나누기 : $212.67 / 64.58 = 3.29$	3.52	125
코미디	5.81	6.21	300
가족	12.65	13.52	120
공포	9.68	10.35	55
열의 합계	310	290	전체 합계 = 600
검정통계량	$3.29 + 3.52 + 5.81 + 6.21 + 12.65 + 13.52 + 9.68 + 10.35 = 65.03$		
자유도	$(r - 1) \times (c - 1) = (4 - 1) \times (2 - 1) = 3$		

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 각 셀의 **검정통계량** 계산

영화 장르	간식류 구매	간식류 비구매	행의 합계
작업	3.29	3.52	125
코미디	5.81	6.21	300
가족	12.65	13.52	120
공포	9.68	10.35	55
열의 합계	310	290	전체 합계 = 600
검정통계량	$3.29 + 3.52 + 5.81 + 6.21 + 12.65 + 13.52 + 9.68 + 10.35 = 65.03$		
자유도	$(r - 1) \times (c - 1) = (4 - 1) \times (3 - 1) = 3$		
비교	검정통계량 (65.03) > 카이제곱 분포표 7.81 ($\alpha = 0.05, df = 3$)		
해석	H0 기각 & H1 채택, 영화장르와 간식류 구매사이에 상관성이 존재한다.		

06. 독립성 검정 : χ^2 검정

(2023년 11월 기준)

◆ 주요 메서드 - 카이제곱 검정

- ✓ 두 범주형 또는 명목형 변수가 서로 연관이 있는 지 가능성 여부를 확인하는 통계 가설 검정

```
1 : from scipy import stats
2 : result = stats.chi2_contingency([X1, X2, X3])
3 : f_score, p_value = result[0], result[1]
4 : print(round(f_score, 4), round(p_value, 4))

30.1275 0.0
```

◆ 메서드 설명

- ✓ 분할표(contingency table)에서 변수의 독립성에 대한 카이제곱 검정.

메서드	매개변수	설명
<code>chi2_contingency(observed)</code>	observed : array_like	분할표를 말하며, 표에는 각 범주에서 관찰된 빈도(즉, 발생 횟수)가 포함되어 있습니다. 2차원의 경우, 이 테이블은 종종 "R x C 테이블"로 설명됨


07. 분산분석

(2023년 11월 기준)

- ◆ 두개 이상의 집단에서 그룹 평균 간 차이를 그룹 내 변동에 비교하여 살펴보는 통계분석 방법
 - ✓ 집단 내에 분산보다 다른 집단과의 분산이 더 크면 유의하다고 할 수 있다는 개념을 가지고 있음


A

Between-group variation
(i.e. Differences among group means)



B

Within-group variation
(i.e. Variability within each group)



- ◆ 두개 이상의 집단에서 그룹 평균 간 차이를 그룹 내 변동에 비교하여 살펴보는 통계분석 방법
 - ✓ 집단 내에 분산보다 다른 집단과의 분산이 더 크면 유의하다고 할 수 있다는 개념을 가지고 있음

구분	명칭	독립변수 개수	종속변수 개수
단일변량 분산분석	일원배치 분산분석	1개	1개
	이원배치 분산분석	2개	
	다원배치 분산분석	3개 이상	
다변량 분산분석	MANOVA	1개 이상	2개 이상

- ◆ 일원배치분산분석 (One-Way ANOVA)
 - ✓ 반응값에 대한 하나의 범주형 변수의 영향을 알아보기 위해 사용되는 검증 방법
 - ✓ 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 된다.
 - ✓ F 검정 통계량을 이용한다.

요인	제곱합	자유도	평균제곱	F-value	P
집단 간	SSB	집단수 - 1	$\frac{\text{집단 간 제곱합}}{\text{자유도}}$	$\frac{\text{집단 간 평균제곱}}{\text{집단 내 평균제곱}}$	-
집단 내	SSW	자료 수 - 집단 수	$\frac{\text{집단 내 제곱합}}{\text{자유도}}$		-
합계	SST	자료 수 - 1	-		-

- ◆ 용어
 - ✓ SST(Sum of Squares) : 총 변동
 - ✓ SSB(Sum of Squares Between) : 집단 간 변동
 - ✓ SSW(Sum of Squares Within) : 집단 내 변동

◆ 일원배치분산분석 (One-Way ANOVA)

- ✓ 반응값에 대한 하나의 범주형 변수의 영향을 알아보기 위해 사용되는 검증 방법
- ✓ 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 된다.
- ✓ F 검정 통계량을 이용한다.

◆ 가정

- ✓ 집단의 측정치는 서로 독립적이어야 한다.
- ✓ 각 집단의 데이터를 정규분포를 따른다.
 - 집단별 크기가 25미만이면, 정규성을 체크함
 - 만약, 정규성 가정 위반시, Kruskal-Wallis Test를 사용함
- ✓ 표본 크기가 매우 다를 때, 분산의 동질성을 확인하며, Levene Test를 사용
 - 만약, 등분산 가정이 위반되면 Welch Test를 사용함

◆ 일원배치분산분석 (One-Way ANOVA)

- ✓ 반응값에 대한 하나의 범주형 변수의 영향을 알아보기 위해 사용되는 검증 방법
- ✓ 모집단의 수에는 제한이 없으며, 각 표본의 수는 같지 않아도 된다.
- ✓ F 검정 통계량을 이용한다.

◆ 가설

- ✓ 귀무가설 : K개의 집단 간 평균에는 차이가 없다.
- ✓ 대립가설 : K개의 집단 간 평균이 모두 같다고 할 수 없다.

◆ 주요 메서드 - 일원배치분산분석 (One Way ANOVA)

- ✓ 일원 분산 분석은 두 개 이상의 그룹이 동일한 모집단 평균을 가지고 있다는 귀무가설을 테스트.
- ✓ 테스트는 크기가 서로 다른 두 개 이상의 그룹의 샘플에 적용됩니다.

```
1 : from scipy import stats
2 : f_score, p_value = stats.f_oneway(X1, X2, X3)
3 : print(round(f_score, 4), round(p_value, 4))
4 : 49.16 0.0
```

◆ 메서드 설명

- ✓ 일원배치분산분석을 수행하며, 각 sample은 Series 형태, array 형태로 오면 된다.

메서드	매개변수	설명
<code>f_oneway(sample1, ...)</code>	<code>sample1</code> : <code>array_like</code>	The sample measurements for each group.

◆ 주요 메서드 - 일원배치분산분석 (One Way ANOVA)

- ✓ 일원 분산 분석은 두 개 이상의 그룹이 동일한 모집단 평균을 가지고 있다는 귀무가설을 테스트.
- ✓ 테스트는 크기가 서로 다른 두 개 이상의 그룹의 샘플에 적용됩니다.
- ✓ 귀무가설 기각, 대립가설 채택 시, 사후검정을 진행해야 함

◆ 사후검정 파이썬 코드 예시

```
1 : from statsmodels.stats.multicomp import pairwise_tukeyhsd
2 : posthoc = pairwise_tukeyhsd(df['outcome_variables'], df['group'])
3 : print(posthoc.summary())
```

```
Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1      group2      meandiff p-adj      lower      upper      reject
-----
setosa versicolor    -0.658      0.0    -0.8189    -0.4971      True
setosa  virginica    -0.454      0.0    -0.6149    -0.2931      True
versicolor virginica    0.204 0.0088    0.0431    0.3649      True
-----
```


◆ 모수 통계 가설 검정


검정 방법	메서드	라이브러리 링크
단일표본 T-검정	.ttest_1samp()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_1samp.html
독립표본 T-검정	.ttest_ind()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_ind.html
대응표본 T-검정	.ttest_rel()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.ttest_rel.html
일원분산분석	.f_oneway()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.f_oneway.html
카이제곱검정(적합도 검정)	.chisquare()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chisquare.html
카이제곱검정(독립성 검정)	.chi2_contingency()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.chi2_contingency.html

◆ 모수 통계 가설 검정

검정 방법	메서드	라이브러리 링크
정규성 검정	.shapiro()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.shapiro.html
등분산성 검정	.levene()	https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.levene.html

◆ 기본 개념

- ✓ 일반적으로 하나의 종속변수 Y 와 여러 독립(=예측)변수 간의 관계를 모델링하는데 사용됨



◆ 선형 회귀 모형 진단

- ✓ 회귀 모형이 적합하려면, 4가지 가정을 모두 만족시켜야 함
- ✓ 예측값과 실제 값의 차이인 잔차(Residual)를 이용하여 검증

가정	의미	진단 방법
선형성	종속변수는 독립변수의 선형 함수	잔차 산점도 : 선형성 확인
독립성	독립변수 사이에는 상관관계가 없어야 함	잔차 산점도 : 특정한 경향성이 없어야 함 더빈-왓슨 검정(Durbin-Watson Test)
등분산성	오차항의 분산은 등분산임	잔차 산점도 : 고르게 분포되어야 함
정규성	오차항의 평균은 0임	Shapiro Wilk 검정 Kolmogorov-Smirnov Goodness of Fit Test Q-Q plot

◆ 검정 설명

- ✓ Shapiro Wil 검정 : 데이터의 정규성을 검증하는 방법
- ✓ Kolmogorov-Smirnov 검정 : 데이터가 예상되는 분포에 얼마나 잘 맞는지를 검정

10. 표준편차 vs. 표준오차

(2023년 11월 기준)

◆ 비교

표준편차(Standard Deviation)	표준오차(Standard Error)
$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$ 표본평균	$S.E = \frac{\sigma}{\sqrt{n}}$ $S.E = \frac{s}{\sqrt{n}}$
✓ 각 데이터가 평균과 얼마나 차이를 가지는지 알려주는 지표	✓ 표본평균의 표준편차 ✓ 추정값인 표본평균들의 참값인 모평균과의 표준적인 차이 ✓ 수식에서 n 이 커지면 표준오차는 줄어듦

